

Московский авиационный институт (национальный исследовательский университет)

Институт № 8 «Компьютерные науки и прикладная математика»
Кафедра 806 «Вычислительная математика и программирование»

Лабораторные работы
по курсу: «Информационный поиск»

Студент: Шипилов К. Ю.
Группа: М8О-403Б-22
Преподаватель: Кухтичев А. А.
Оценка: _____

Москва, 2025

1 Задание

Необходимо разработать поисковую систему, включающую следующие компоненты:

1. **Сбор данных (Crawler):** Робот для автоматического скачивания текстовых документов из Интернета.
2. **Лингвистическая обработка:** Токенизация текста и стемминг для русского и английского языков.
3. **Анализ:** Проверка выполнения закона Ципфа для собранного корпуса.
4. **Индексация:** Программа на языке C++ для построения инвертированного индекса.
5. **Поиск:** Реализация булева поиска (операторы AND, OR) по построенному индексу.

2 Описание метода решения

Система разделена на два модуля: модуль сбора данных (Python) и модуль индексации/поиска (C++). Также дополнительно реализованы скрипты на Python для экспорта данных из MongoDB в текстовый файл и для визуализации закона Ципфа.

1 Сбор данных

В качестве корпуса были документов были выбраны спортивные новости на русском языке из kp.ru и sportrbc.ru. Для сбора данных использовался поисковой робот на Python. Оба источника имеют удобные Sitemap-файлы, что значительно упростило навигацию по сайту и сбор ссылок на новости. Для каждого источника робот запускается в отдельном потоке и отправляет запрос на страницу из Sitemap с учетом задержки между запросами (2 секунды) для предотвращения блокировки. После получения HTML страницы с новостью, из нее извлекается контейнерный тег, содержащий только статью без элементов навигации, после чего загруженная статья сохраняется в MongoDB. Для простоты дальнейшей работы с данными используется скрипт, который экспортирует текущие данные из MongoDB в текстовый файл в следующем формате:

```
URL документа
Источник (новостной портал)
Заголовок статьи
Текст статьи
```

Каждый документ занимает ровно 4 строки, что упрощает чтение и обработку данных в программе на C++.

2 Индексация и Поиск

Ядро поисковой системы написано на C++. В соответствии с требованиями, основные структуры данных для индекса реализованы самостоятельно без использования контейнеров STL.

2.1 Структуры данных

Были реализованы следующие классы:

- **HashMap<T>**: Самописная хеш-таблица с методом цепочек для разрешения коллизий. Используется для хранения терминов и соответствующих им списков документов.
- **Node**: Узел хеш-таблицы, содержащий ключ (термин), значение и указатель на следующий узел в цепочке.
- **PostingList**: Структура для хранения списка идентификаторов документов, содержащих данный термин.

Хеш-функция для строк основана на алгоритме djb2:

```
unsigned long hash_utf8(const std::string& s) {  
    unsigned long h = 5381;  
    for (unsigned char c : s)  
        h = ((h << 5) + h) + c;  
    return h;  
}
```

2.2 Лингвистическая обработка

При индексации применяется следующий конвейер обработки текста:

1. **Токенизация**: Разбиение текста на слова по не-буквенным символам. Учитывается кодировка UTF-8 для корректной обработки русских букв.
2. **Приведение к нижнему регистру**: Собственная реализация для UTF-8, преобразующая как латинские, так и кириллические символы.
3. **Стемминг**: Упрощенный стеммер, удаляющий наиболее частые окончания для русского и английского языков.

2.3 Инвертированный индекс

Индекс строится как хеш-таблица, где ключами являются термины (после обработки), а значениями – списки идентификаторов документов (URL), в которых встречается данный термин.

2.4 Булев поиск

Поиск осуществляется путем операций над списками DocID. Реализованы две основные операции:

- **AND (Intersect):** Пересечение двух списков документов ($O(\min(n, m))$, где n и m – размеры списков).
- **OR (Unite):** Объединение двух списков документов с устранением дубликатов ($O(n + m)$).

3 Результаты и тестирование

1 Сбор корпуса документов

Был произведен сбор спортивных новостей с различных русскоязычных новостных порталов.

- Общее количество документов: 30 387.
- Объем сырых данных: ≈ 1 ГБ.
- Объем извлеченного текста: ≈ 100 МБ.

2 Характеристики индекса

После индексации корпуса получены следующие характеристики:

- Уникальных терминов (после стемминга): 106 003.
- Общее количество термов (с учетом повторений): 4 218 262.




Рис. 1: Распределение частот терминов в корпусе спортивных новостей

3 Проверка закона Ципфа

Для проверки закона Ципфа была построена статистика частотности терминов по всему корпусу. На рис. 1 показано распределение частот в логарифмическом масштабе.

Распределение демонстрирует основные характеристики закона Ципфа:

- Наиболее частые термины: предлоги и союзы
- Средняя часть графика показывает ожидаемую линейную зависимость в логарифмических координатах
- Хвост распределения содержит редкие термины, характерные для спортивной тематики

Отклонения от идеального закона Ципфа объясняются особенностями корпуса:

1. **Тематическая специфика:** Спортивные новости содержат много терминов, характерных только для этой области ("матч "гол "команда "чемпионат"), что повышает их относительную частоту.

2. **Агрессивный стемминг:** Упрощенный стеммер объединяет различные формы слов, что увеличивает частоту основных форм.
3. **Структура новостей:** Заголовки и лиды новостей часто содержат одни и те же ключевые слова, что влияет на распределение частот.

4 Тестирование поиска

Ниже приведены примеры работы программы для различных поисковых запросов.

Пример 1. Одиночный запрос Запрос: футбол

Found 4278 document(s) for query: "футбол"

1. Кто сейчас тренирует сборную Италии к Евро-2020 по футболу: Роберто Манчини - крестный отец дебютантов

URL: <https://www.kp.ru/sports/futbol/kto-sejchas-treniruet-sbornuyu-italii-k-evro-2020>

Source: kp_sport

2. Главный фанат сборной Турции - президент Эрдоган. Он мечтал о карьере футболиста

URL: <https://www.kp.ru/sports/futbol/glavnyj-fanat-sbornoj-turczii-prezident-erdogan>

Source: kp_sport

3. Кто сейчас тренирует сборную Уэльса: Роб Пейдж - заместитель Гиггза

URL: <https://www.kp.ru/sports/futbol/kto-sejchas-treniruet-sbornuyu-uelsa-rob-pejdzha>

Source: kp_sport

4. Швейцария - столица футбола и спорта. Правительство страны сделало это специально

URL: <https://www.kp.ru/sports/futbol/shvejczariya-stolicza-futbola-i-sporta>

Source: kp_sport

5. Состав сборной Хорватии на Евро-2020 по футболу: шансы и амбиции

URL: <https://www.kp.ru/sports/futbol/sostav-sbornoj-horvatii-na-evro-2020-po-futbolu>

Source: kp_sport

... and 4273 more document(s)

Пример 2. Одиночный запрос Запрос: матч

Found 16974 document(s) for query: "матч"

1. Кто сейчас тренирует сборную Уэльса: Роб Пейдж - заместитель Гиггза

URL: <https://www.kp.ru/sports/futbol/kto-sejchas-treniruet-sbornuyu-uelsa-rob-pejdzh-z>
Source: kp_sport

2. Швейцария - столица футбола и спорта. Правительство страны сделало это специально
URL: <https://www.kp.ru/sports/futbol/shvejczariya-stolicza-futbola-i-sporta>
Source: kp_sport

3. В Санкт-Петербурге пройдет семь встреч Евро
URL: <https://www.kp.ru/sports/futbol/v-sankt-peterburge-projdet-sem-vstrech-evro>
Source: kp_sport

4. Вундертим - команда Австрии, которой не дали стать чемпионской
URL: <https://www.kp.ru/sports/futbol/vundertim-komanda-avstrii-kotoroj-ne-dali-stat-cl>
Source: kp_sport

5. Кто сейчас тренирует сборную Нидерландов: Франк де Бур - специалист с ярлыком неудачника
URL: <https://www.kp.ru/sports/futbol/kto-sejchas-treniruet-sbornuyu-niderlandov-frank>
Source: kp_sport

... and 16969 more document(s)

Пример 3. Булево И (AND) Запрос: футбол AND матч

Found 3171 document(s) for query: "футбол AND матч"

1. Кто сейчас тренирует сборную Уэльса: Роб Пейдж - заместитель Гиггза
URL: <https://www.kp.ru/sports/futbol/kto-sejchas-treniruet-sbornuyu-uelsa-rob-pejdzh-z>
Source: kp_sport

2. Швейцария - столица футбола и спорта. Правительство страны сделало это специально
URL: <https://www.kp.ru/sports/futbol/shvejczariya-stolicza-futbola-i-sporta>
Source: kp_sport

3. Состав сборной Хорватии на Евро-2020 по футболу: шансы и амбиции
URL: <https://www.kp.ru/sports/futbol/sostav-sbornoj-horvatii-na-evro-2020-po-futbolu-s>
Source: kp_sport

4. Кто придумал петь гимны перед матчами
URL: <https://www.kp.ru/sports/futbol/kto-pridumal-pet-gimny-pered-matchami>
Source: kp_sport

5. Турки, сирийцы, афганцы и африканцы - тоже немцы, если речь идет о футболе

URL: <https://www.kp.ru/sports/futbol/turki-sirijczy-afganczy-i-afrikanczy-tozhe-nemczy>

Source: kp_sport

... and 3166 more document(s)

Пример 4. Булево ИЛИ (OR) Запрос: футбол OR матч

Found 18081 document(s) for query: "футбол OR матч"

1. Кто сейчас тренирует сборную Италии к Евро-2020 по футболу: Роберто Манчини - крестный отец дебютантов

URL: <https://www.kp.ru/sports/futbol/kto-sejchas-treniruet-sbornuyu-italii-k-evro-2020>

Source: kp_sport

2. Главный фанат сборной Турции - президент Эрдоган. Он мечтал о карьере футболиста

URL: <https://www.kp.ru/sports/futbol/glavnyj-fanat-sbornoj-turczii-prezident-erdogan>

Source: kp_sport

3. Кто сейчас тренирует сборную Уэльса: Роб Пейдж - заместитель Гиггза

URL: <https://www.kp.ru/sports/futbol/kto-sejchas-treniruet-sbornuyu-uelsa-rob-pejdzha>

Source: kp_sport

4. Швейцария - столица футбола и спорта. Правительство страны сделало это специально

URL: <https://www.kp.ru/sports/futbol/shvejczariya-stolicza-futbola-i-sporta>

Source: kp_sport

5. Состав сборной Хорватии на Евро-2020 по футболу: шансы и амбиции

URL: <https://www.kp.ru/sports/futbol/sostav-sbornoj-horvatii-na-evro-2020-po-futbolu>

Source: kp_sport

... and 18076 more document(s)

4 Выводы

В ходе выполнения работы была реализована поисковая система, обеспечивающая эффективный сбор данных, лингвистическую обработку, индексацию и поиск по корпусу спортивных новостей. Система демонстрирует хорошую производительность при поиске по корпусу из 30 000 документов. Работа позволила глубже понять принципы работы с информационными системами и большим объемом данных.

Список литературы

- [1] Маннинг К., Рагхаван П., Шютце Х. Введение в информационный поиск. — М.: Вильямс, 2011. — 528 с.
- [2] Митчелл Р. Скрапинг веб-сайтов с помощью Python. — Litres, 2022.